



Máster Smart Energy

INTRODUCCIÓN A MACHINE LEARNING

Postgrado de DIGITAL ENERGY

Curso 2022/2023

Sesión 3 – Estadística Descriptiva y
Análisis Exploratorio de Datos (EDA)



Calendario

	Lunes	Martes	Miércoles	Jueves
ABRIL	10	11	12 S1 – Introducción a Machine Learning	13
	17 S2 – Introducción a Python	18	19 S3 – Estadística descriptiva	20
	24 S4 – Modelos de aprendizaje supervisado (I): Clasificación	25	26 S5 – Modelos de aprendizaje supervisado (II): Regresión	27
MAYO	1	2	3 S6 – Aplicación de AI en el sector eléctrico: Odit-e	4
	8 S7 – Modelos de aprendizaje no supervisado	9	10 S8 – Examen final	

Sara Barja : sara.barja@upc.edu

Marc Jené: marc.jene@upc.edu



¿Qué es el análisis exploratorio de datos?

Es una forma de analizar datos, un proceso crítico que consiste en realizar **investigaciones iniciales** sobre los datos para descubrir patrones, detectar anomalías, probar hipótesis y comprobar supuestos con la ayuda de estadísticas de resumen y representaciones gráficas.


Es una buena práctica **entender primero los datos** y tratar de obtener la mayor cantidad de información posible de ellos. El análisis exploratorio de datos consiste en dar sentido a los datos que se tienen a mano, **antes de empezar a tratarlos** y “ensuciarlos”.




Muestra vs. Población

Normalmente nos encontraremos en una situación donde deseamos responder preguntas sobre una *población* pero solo tenemos acceso a una *muestra*.

Para responder
preguntas sobre una
Población



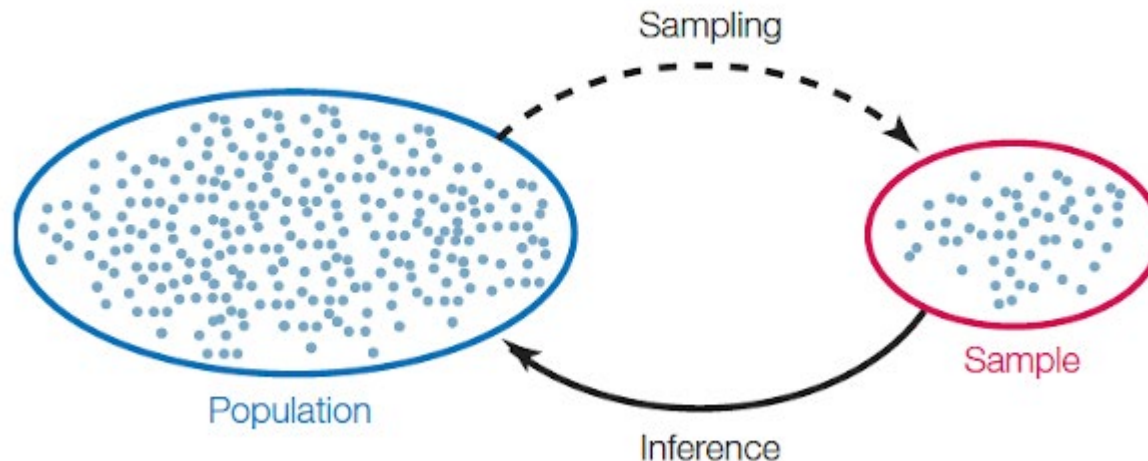
Tenemos que aprender
a trabajar con una
Muestra





Muestra vs. Población

La *población* se refiere a todos los individuos que son relevantes para una pregunta en concreto, mientras que una *muestra* será solo un subset de estos. Por ejemplo, todos los clientes de una compañía de distribución serán la población, mientras que para hacer un estudio a lo mejor solo usamos una muestra de ellos.

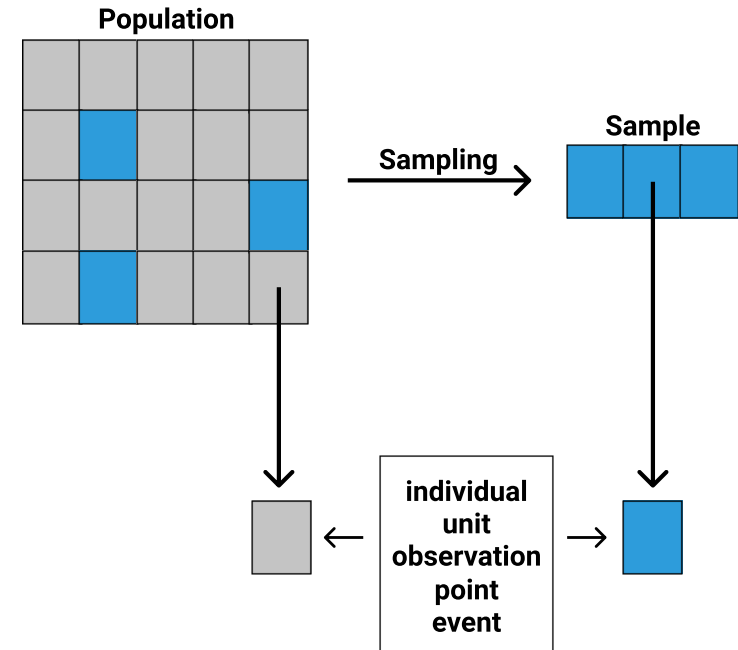




Muestra vs. Población

Las poblaciones y las muestras están formadas por varias observaciones, individuos, elementos, etc.

Siempre que se pueda, será mejor usar la población para responder a nuestras preguntas, pero a veces esto no es posible (no se tienen todos los datos, recopilar todos los datos en una misma fuente es difícil, etc.). En estos casos usaremos una muestra.





Muestra vs. Población - Resumen

Población: Todos los individuos que son relevantes para una pregunta en concreto.

Muestra: Subset de la población.

Muestreo: Obtener muestra de población.

Inferencia: Obtener conclusiones para una población partiendo de una muestra.

$$\text{error de estimación} = \text{parámetro (población)} - \text{estadística (muestra)}$$

Para mejorar el muestreo:

- Varias muestras y trabajar con promedios.
- Intentar acercarnos al máximo a toda la población (más observaciones).
- Muestreo estratificado (*stratified sampling*), para que sea significativo.



Limpieza y resumen de datos

Antes de ajustar un modelo de ML, **siempre tenemos que limpiar los datos**. Ningún análisis crea resultados significativos con datos confusos.

La limpieza de datos (*data cleaning*) o depuración de datos (*data cleansing*) es el proceso de detectar y corregir (o eliminar) los datos corruptos o inexactos de un set de datos.

Consta de dos procesos básicos:

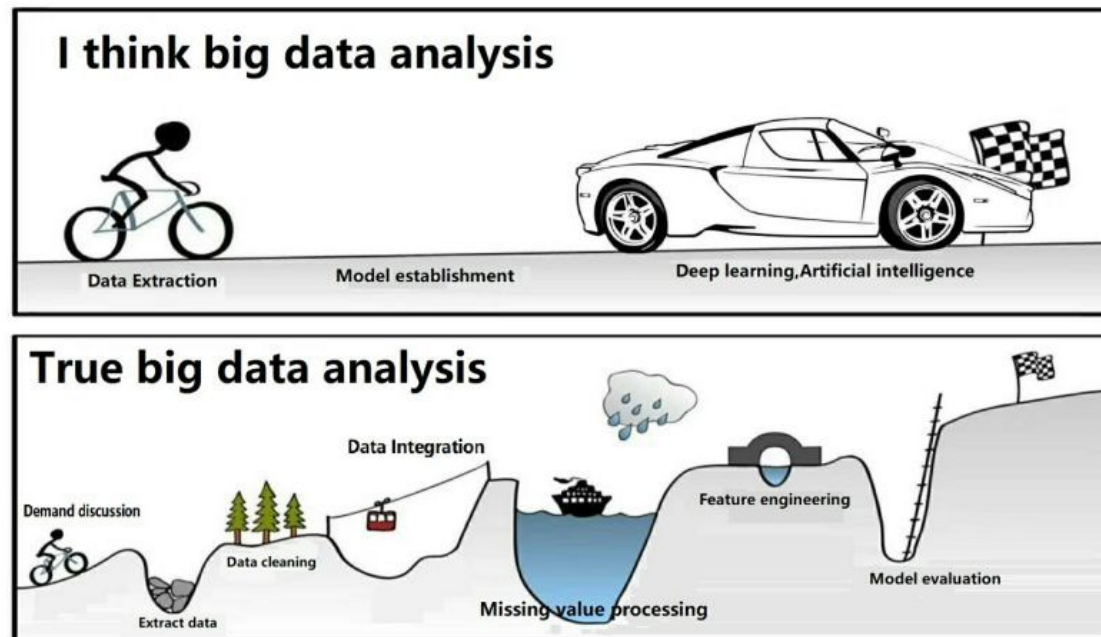
- Identificación de las partes incompletas, incorrectas, inexactas o irrelevantes de los datos.
- Sustitución, modificación o eliminación de los datos inadecuados.

A la práctica, los datos brutos son casi siempre desordenados. Si utilizas esos datos para el análisis, por ejemplo, alimentando un modelo de aprendizaje automático, obtendrás conocimientos inútiles o erróneos la mayoría de las veces.



Limpieza y resumen de datos

Desde luego, la limpieza de datos no es divertida y requiere mucho tiempo.





Limpieza y resumen de datos

Un *data scientist* pasa el 80% de su tiempo en el trabajo limpiando datos desordenados en lugar de hacer un análisis de estos o preparar modelos de inteligencia artificial.

La librería *pandas* nos ofrece varias opciones para obtener un resumen de los datos como el método *describe*, u otros como *sum*, *count*, *min*, *max*, *mean*...

A parte, también son interesantes para obtener distribuciones de frecuencia los métodos *value_counts* i *nunique*.





Limpieza y resumen de datos

Hay varias opciones para tratar con valores vacíos, pero pandas nos ofrece algunas opciones rápidas e interesantes para ir rápido.

Funciones interesantes

df.isna() – Detecta los valores ausentes/nulos (NA).

df.dropna() – Elimina las filas con cualquier columna que tenga datos NA.

df.fillna() - Sustituye todos los datos NA por el valor deseado. Este método con los valores NA de tres maneras distintas.

- `method = 'bfill'`: reemplaza por valor no nulo observado hacia delante de la serie de datos.
- `method = 'ffill'`: reemplaza por valor no nulo observado hacia atrás de la serie de datos.
- `method = explicit value`.



También nos puede interesar el método **df.interpolate()**.





Limpieza y resumen de datos – Pasos a seguir

- **Muestreo de datos.** Si hay muchos datos y el tiempo de cómputo puede ser demasiado grande se trabaja primero con solo una muestra
- **Valores ausentes.** Es usual que muchos parámetros estén vacíos. Para pasar a pasos posteriores esto se debe arreglar. Si faltan valores, podemos:
 - Eliminar toda la fila.
 - Inferir otro valor.
- **Valores atípicos.** Son valores inusuales en un conjunto de datos. Los valores atípicos son problemáticos para muchos análisis estadísticos porque pueden hacer que las pruebas no detecten resultados significativos o distorsionen los resultados reales. Dependiendo de cada caso, se deben considerar y tener en cuenta o pueden tratarse igual que los valores ausentes (se pueden eliminar o sustituir por valores típicos).





Limpieza y resumen de datos – Sigüientes pasos

- **Normalizar.** Transformar los datos a distribuciones normalizadas.
- **Reducir dimensiones.** Muchas variables nos pueden causar problemas en Machine Learning. Para eliminar variables podemos:
 - a) Eliminar variables irrelevantes.
 - b) Eliminar variables redundantes.
- **Añadir dimensiones.** En otros casos haremos lo contrario y transformaremos o añadiremos variables (Ejemplo: crear grupos).
- **Discretizar variables numéricas en categorías.** Pasar de una variable continua a categórica (edad a tramos de edad).
- **Binarizar categorías.** En algunos casos de Machine Learning, tendremos que usar variables binarias.

Human-Readable	Machine-Readable			
Pet	Cat	Dog	Turtle	Fish
Cat	1	0	0	0
Dog	0	1	0	0
Turtle	0	0	1	0
Fish	0	0	0	1
Cat	1	0	0	0



Estadística descriptiva

Tipos de variables


Las variables pueden ser nominales, ordinales, continuas o discretas.





Estadística descriptiva

Clasificación de Variables








Estadística descriptiva

Media, mediana y moda

Una vez tenemos un resumen de los datos usados, unos parámetros que nos pueden ser muy útiles para conocer como se distribuyen ciertas características de nuestro *dataset* son:

- Media aritmética: Valor promedio
- Mediana: Posición intermediaria Ord. jerárquicamente
- Moda: Valor que mas veces se frecuenta.







Estadística descriptiva

Variabilidad

La variabilidad es una medida de la dispersión de los datos en una distribución, sea esta teórica o de una muestra; medidas de variabilidad son

- Varianza: Es el cuadrado de la desviación de dicha variable respecto a su media.
- Desviación estándar: es una medida que se utiliza para cuantificar la variación o la dispersión de un conjunto de datos numéricos.
- Rango: Es la diferencia entre el valor máximo y mínimo





Estadística descriptiva


Tablas de frecuencia

Las tabla de frecuencias muestran de forma ordenada un conjunto de datos estadísticos y a cada uno de ellos le asigna una frecuencia (las veces que se repite un número o dato). Hay distintos tipos de frecuencias:

- Frecuencia absoluta
- Frecuencia absoluta acumulada
- Frecuencia relativa
- Frecuencia relativa acumulada

La mejor manera de comparar y evaluar distintas tablas de frecuencia es visualizarlas.


X_i	Frecuencia absoluta (n_i)	Frecuencia absoluta acumulada (N_i)	Frecuencia relativa ($f_i = n_i/N$)	Frecuencia relativa acumulada ($F_i = N_i/N$)
1	18	18	0.20	0.20
2	13	31	0.15	0.35
3	9	40	0.10	0.45
4	9	49	0.10	0.56
5	16	65	0.18	0.74
6	5	70	0.06	0.80
7	6	76	0.07	0.86
8	12	88	0.14	1.00
Total	88		1	





Estadística descriptiva

Asimetría: Se refiere a una distorsión o asimetría que se desvía de la curva de campana simétrica, o distribución normal, en un conjunto de datos. Si la curva se desplaza hacia la izquierda o hacia la derecha, se dice que está sesgada.





Bibliografía recomendada

1. EDA <https://towardsdatascience.com/exploratory-data-analysis-8fc1cb20fd15>
2. EDA y limpieza de datos
<https://towardsdatascience.com/exploratory-data-analysis-and-data-cleaning-practical-workout-2a20442b42fb>
3. Pipeline de EDA y limpieza de datos
<https://medium.com/@oluwabukunmige/pipeline-for-exploratory-data-analysis-and-data-cleaning-6adce7ac0594>
4. Funciones pandas
<https://pandas.pydata.org/docs/reference/frame.html>